

Desenvolvimento e Avaliação de Algoritmos de Trading para Criptomoedas

Trabalho de Conclusão

Luís Gabriel Pacheco Marquetti
Escola Politécnica, PUCRS

Orientadora: Profa. Dra. Andréa Aparecida Konzen

Julho 2024

Roteiro da Apresentação

- 1) Justificativa do trabalho
- 2) Objetivos do trabalho
- 3) Metodologia
- 4) Trabalho desenvolvido
- 5) Resultados
- 6) Conclusão e trabalhos futuros
- 7) Principais referências

1) Justificativa do trabalho

As criptomoedas experimentaram uma ampla aceitação e rápido desenvolvimento na última década. O valor de mercado das criptomoedas é superior a 2 trilhões de dólares.

Seus preços exibiram valorização e volatilidade, influenciados por vários fatores: o desenvolvimento tecnológico, o sentimento de mercado, regulamentação e eventos macroeconômicos.

Fundos de financeiros começaram a incluir criptomoedas em suas carteiras e estratégias de negociação.

O interesse pela propriedade de criptomoedas e desenvolvimento de estratégias de negociação estão em ascensão nas instituições financeiras e na academia.

Espaço ideal para implementação de algoritmos de trading com o estabelecimento de regras automatizadas para executar ordens de compra ou venda.

2) Objetivos do trabalho

O objetivo principal do trabalho é desenvolver e avaliar algoritmos de negociação automática de criptomoedas entre maio de 2021 a junho de 2024.

Três algoritmos com base em indicadores técnicos, reversão a média, cruzamento de média e aprendizado de máquina são implementados e comparados com a estratégia de comprar e manter um dólar em Bitcoin.

São avaliados o retorno e o risco do investimento no período em estudo.

As negociações foram consideradas em três frequências: 1 hora, 12 horas e 24 horas.

3) Metodologia

Algoritmos Testados:

1) *Reversão à Média*: os preços dos ativos tendem a retornar a sua média histórica. Estratégia baseada no quão distante o preço atual está do preço médio. A média móvel simples foi calculada para as últimas 40 observações.

Vende Bitcoin se o preço houver superado a média móvel simples.

Compra Bitcoin se o preço for menor do que a média móvel observada.

2) *Cruzamento de média móvel*: médias móveis de curto e longo prazo para identificar os momentos da compra e venda. Isso envolve capturar os momentos nos quais há um cruzamento das médias móveis.

Quando a média móvel curta ultrapassa a longa, há indício de valorização e indicação de compra.

Quando a média longa ultrapassa a curta, um indício de desvalorização, então devemos vender.

Período de 4 observações para calcular a média móvel de curto prazo, e de 9 para a de longo prazo.

A média móvel simples foi utilizada na análise.

3. O modelo de aprendizado: baseado em rede neural.

O modelo usa como *input* alguns indicadores técnicos diferentes, como RSI e média móvel exponencial.

A camada final do modelo funciona como um classificador, dividindo o retorno esperado em 4 classes.

São calculados os retornos esperados para o conjunto de dados de teste, o qual é comparado com os retornos do conjunto dos dados de treino.

A estratégia adotada é a seguinte:

Comprar se o retorno esperado para o próximo período estiver no quarto quartil dos retornos passados.

Não toma nenhuma ação se o retorno esperado estiver no segundo ou terceiro quartis.

Vender se o retorno esperado estiver no primeiro quartil.

A comparação entre as estratégias de negociação

Retorno: mede o lucro ou prejuízo gerado por uma estratégia de negociação, expresso como o retorno médio diário em comparação ao "buy and hold".

Volatilidade: mede a variabilidade dos retornos, sendo uma medida de risco. Foi utilizado a variância dos retornos das estratégias utilizadas.

Menor valor, Maior valor e Taxa de acertos: o menor valor indica o menor valor que a estratégia alcançou em relação ao "buy and hold"; o maior valor representa o mais alto valor alcançado em relação ao "buy and hold". A taxa de acertos é medida pelo percentual de observações em que o valor da estratégia foi superior ao "buy and hold" no fechamento das frequências analisadas.

Cada estratégias de negociação foi testada com dados do período de 10/05/2021 até o dia 23/6/2024.

Foram considerados 3 diferentes intervalos de amostragem: 1 hora, 12 horas e 24 horas.

4) Trabalho desenvolvido

As estratégias apresentadas foram desenvolvidas em Python usando pandas, numpy e pytorch.

As informações sobre os preços do Bitcoin foram obtidas a partir da API da Binance.

A seguir foram realizados os *backtests* das estratégias automatizadas.

O *backtest* é um procedimento para avaliar o desempenho de estratégias de negociação. Ele envolve simular a execução da estratégia usando dados históricos de mercado para avaliar sua efetividade em termos de retorno e volatilidade em diversas condições de mercado.

O *backtest* permite a avaliação e refinamento dos algoritmos e na identificação de seus pontos fortes e fracos antes de sua implementação no mundo real.

Portanto, ele envolve a implementação da estratégia, a execução da simulação com os dados históricos e a avaliação do desempenho das estratégias.




Fig. 1. Resultado do backtest para as estratégias de cruzamento de médias e comprar e manter para a frequência de 1 hora.

```
class Net(nn.Module):

    def __init__(self):
        super(Net, self).__init__()
        self.linear1 = nn.Linear(12,40)
        self.activation = nn.ReLU()
        self.linear2 = nn.Linear(40,30)
        self.linear3 = nn.Linear(30,20)
        self.linear4 = nn.Linear(20,10)
        self.linear5 = nn.Linear(10,5)
        self.linear6 = nn.Linear(5,4)
        self.output_layer = nn.Linear(4,4)
        self.softmax = nn.Softmax()
        self.layer_list = [self.linear1, self.linear2,
                            self.linear3, self.linear4,
                            self.linear5, self.linear6]

    def forward(self, x):
        for layer in self.layer_list:
            x = layer(x)
            x = self.activation(x)
        x = self.output_layer(x)
        output = self.softmax(x)
        return output
```

Fig. 2. Definição da arquitetura do modelo testado




Fig. 3. Preço diário do Bitcoin em dólares na Binance, 10/05/2021-23/06/2024

5) Resultados

Um aspecto importante a considerar é que os resultados das estratégias de cruzamento de média móvel e de reversão à média não são diretamente comparáveis aos resultados da rede neural, uma vez que essa última requer um período de treinamento

A rentabilidade para as diferentes frequências de amostragem foram calculados para um período de 24 horas.

Tabela 1. Retorno diário percentual das estratégias com diferentes frequências de negociação.

	1hora	12horas	24horas
Cruzamento de Média Móvel	-0.0274	-0.0046	0.0073
Reversão à Média	0.0395	0.0752	0.1128
Buy and Hold	0.0528	0.0499	0.0532
Rede Neural	0.1495	0.6012	nd
Buy and Hold	0.2204	0.5613	nd

Nota: nd - não disponível

Tabela 2. Variância do retorno das estratégias com diferentes frequências de negociação.

Estratégia	1hora	12 horas	24 horas
Cruzamento de Média Móvel	0.0000412	0.0002187	0.0004135
Reversão à Média	0.0000200	0.0004616	0.0004096
Buy and hold	0.0000401	0.0002648	0.0008847
Rede Neural	0.0000146	0.0111757	nd
Buy and hold	0.0000237	0.0002908	nd

Nota: nd - não disponível

Tabela 3. Comparação entre os portfólios das estratégias com algoritmo de trade e buy and hold: o menor valor e o maior valor relativos e o percentual das observações com portfólio superior ao buy and hold para diferentes frequências.

Estratégia	Menor Valor	Maior Valor	Observações
Cruzamento de Média Móvel			
1hora	0.601	1.821	46.53
12 horas	0.629	1.574	29.91
24 horas	0.661	2.094	80.98
Reversão à Média			
1hora	0.966	2.299	99.56
12 horas	0.924	2.098	86.82
24 horas	0.936	2.460	93.94
Rede Neural			
1hora	0.412	1.212	28.59
12 horas	0.851	1.131	84.42

6) Conclusão e trabalhos futuros

Para a frequência de uma hora, a melhor opção é "buy and hold". Na frequência de 12 horas, as estratégias de reversão à média e redes neurais tiveram desempenho superior ao comprar e manter.

Com 24 horas, a estratégia de reversão à média teve o dobro do rendimento do "buy and hold", além de apresentar menor variância, um indicador de risco.

O aumento da rentabilidade e a redução da volatilidade foram observados em um período em que o preço do Bitcoin apresentou fases de expansão e contração.

Com a redução da frequência houve um aumento do retorno em todas as estratégias ativas de negociação. A frequência também influencia os resultados das negociações no mercado de criptomoedas.

Há possibilidades de algoritmos de negociação desempenharem um papel importante nos resultados obtidos no mercado de criptomoedas.

Pesquisas futuras devem se aprofundar na otimização de parâmetros e hiperparâmetros dos algoritmos, incorporando novas técnicas de aprendizado de máquina para um desempenho mais adaptativo.

A consideração de informações adicionais, como os dados de volume de negociação, pode melhorar ainda mais a eficácia dos robôs de negociação.

É possível analisar os resultados para outras criptomoedas, como o Ethereum.

A inclusão de dados fundamentalistas, como a taxa de juros no mercado internacional, abre a possibilidade de combinar estratégias de negociação técnica e fundamentalista.

O estudo oferece sugestões valiosas para a negociação de criptomoedas, destacando o potencial dos algoritmos de trading para gerar resultados positivos no mercado financeiro.

Implementar as estratégias no mundo real.

7) Principais referências

- [17] M. Nakano, A. Takahashi, and S. Takahashi, “Bitcoin technical trading with artificial neural network,” *Physica A: Statistical Mechanics and its Applications*, vol. 510, pp. 587–609, 2018.
- [23] Binance, “Binance api documentation.” <https://binance-docs.github.io/apidocs/spot/en/>. Accessed on: June 30, 2024.
- [5] F. Fang, C. Ventre, M. Basios, L. Kanthan, D. Martinez-Rego, F. Wu, and L. Li, “Cryptocurrency trading: a comprehensive survey,” *Financial Innovation*, 2022.
- [11] Y. Sovbetov, “Factors influencing cryptocurrency prices: Evidence from bitcoin, ethereum, dash, litecoin, and monero,” *Journal of Economics and Financial Analysis*, vol. 2, no. 2, pp. 1–27, 2018.
- [14] I. Nti, A. Adekoya, and B. Weyori, “A systematic review of fundamental and technical analysis of stock market predictions,” *Artificial Intelligence Review*. vol. 53. 04 2020.
- [19] B. Barber and T. Odean, “Does online trading change investor behavior?,” *European Business Organization Law Review*, vol. 3, pp. 83 – 128, 03 2002.
- [21] G. Cohen and M. Qadan, “The complexity of cryptocurrencies algorithmic trading,” *Mathematics*, vol. 10, no. 12, 2022.
- [22] K. Zbikowski, “Application of machine learning algorithms for bitcoin automated trading,” 2016.

Muito obrigado.